Hafta / tarih: 4. Hafta 21.10.2026 – 28.10.2026

Çalıştığım konu: Data Science ve Pandas. Veriyi modelden önce tanıma, kalite kontrolü ve temel keşifçi veri analizi yapma.

Kullandığım kaynaklar: Kaggle Learn – Pandas
Kaggle Datasets
Google Colab

Öğrendiğim yeni kavramlar:

DataFrame ve Series veri yapısı mantığı

Sayısal ve kategorik değişken ayrımı

Eksik veri tespiti (isnull) ve doldurma/temizleme stratejileri (fillna)

loc ve iloc ile koşullu veri filtreleme

Sınıf dengesizliği (class imbalance) kontrolü

apply() fonksiyonu ile satır bazlı yeni özellik türetme ve vektörel merkezileştirme

Yaptığım uygulama: Titanic veri seti üzerinde veri yükleme, boyut kontrolü, veri tipleri incelemesi, eksik veri ve aykırı değer tespiti yapma. Sayısal ve kategorik sütunlar analiz edildikten sonra loc/iloc ve isin() filtrelemeleri uygulama. Yaş sütunundaki eksiklikleri medyanla tamamlama, bilet ücreti (Fare) merkezileştirme ve apply() ile Yolcu_Grubu adında yeni bir kategorik özellik üretme. Hedef değişken (2urvived) ile girdi özellikleri (X) ayrılarak modelleme öncesi boyut ve eksik veri kontrolleri gerçekleştirme.

Kullandığım veri seti: Titanic Veri Seti (train_and_test2.csv)

Ürettiğim notebook / dosya: 04_data_exploration.ipynb

Öğrendiğim en önemli 3 şey:

Modelden Önce Veri Keşfinin Önemi: Makine öğrenmesi modelleri eksik (NaN) değerlerle çalışamadığından, modelleme öncesinde veri tipleri ve eksik verilerin mutlaka kontrol edilip temizlenmesi gerekir.

Sınıf Dengesizliği (Target Balance) Kontrolü: Hedef değişkendeki sınıfların oranına bakılmalıdır. Oran dağılımlar bilinmezse modelin yanıltıcı yüksek başarı üretebileceği göz önünde bulundurulmalıdır.

Özet İstatistiklerden Aykırı Değer Okuma: describe() tablosundaki ortalama, medyan ve maksimum değerler arasındaki büyük farkların aykırı değerlere işaret ettiği kolayca analiz edilebilir.

Zorlandığım konu: apply() fonksiyonu ile satır bazında (axis='columns') çoklu koşul kullanarak yeni kategorik değişken türetirken ve eksik verileri doldurduktan sonra girdi matrisinde (X) kalan eksik verileri sıfırlama adımlarında dikkatli işlem yapma gerekliliği.

Sormak istediğim konu: Girdi matrisinde (X) Embarked sütunundan kaynaklanan 2 adet eksik veriyi modele vermeden önce satır bazında silmek mi yoksa en sık tekrar eden (mod) değerle doldurmak mı daha doğru bir yaklaşımdır?

Gelecek hafta hedefim: Hafta 5 konum olan Veri Analizi ve Görselleştirme konularına çalışmak.