Hafta / tarih: 4. Hafta 21.10.2026 – 28.10.2026

Çalıştığım konu: Data Science ve Pandas. Veriyi modelden önce tanıma, kalite kontrolü ve temel keşifçi veri analizi yapma.

Kullandığım kaynaklar: Kaggle Learn – Pandas
Kaggle Datasets
Google Colab

Öğrendiğim yeni kavramlar:

DataFrame ve Series veri yapısı mantığı (index_col="PassengerId" ile indeks yapılandırma)

Sayısal ve kategorik değişken ayrımı, veri tipleri (dtypes) kontrolü ve tip dönüşümü (astype(str))

Eksik veri tespiti (isnull) ve doldurma/temizleme stratejileri (fillna)

loc ve iloc ile koşullu veri filtreleme

apply() fonksiyonu ile satır bazlı (axis='columns') çok koşullu yeni özellik türetme

Yaptığım uygulama: Orijinal Titanic veri seti (891 satır, 11 sütun) üzerinde PassengerId indekse alınarak keşifçi veri analizi yapıldı. Eksik veri kontrolünde Age, Cabin ve Embarked sütunlarındaki boşluklar tespit edildi. Veri temizleme aşamasında Age sütunundaki eksikler medyanla (28), Embarked sütunundaki 2 eksik değer en sık tekrar eden mod ('S') ile tamamlandı ve Cabin için 'Unknown' etiketi atandı. Pclass kategorik analiz için string'e çevrildi. Fare sütunu genel ortalama çıkarılarak vektörel merkezileştirildi (Centered_Fare ortalaması 0 yapıldı). apply() fonksiyonu kullanılarak yaş ve cinsiyete dayalı 3 sınıflı Yolcu_Grubu kategorik değişkeni türetildi. Son olarak hedef değişken (Survived) ile model girdileri ayrıştırıldı ve hedef sınıfların dağılımı incelendi ve girdi matrisinde 0 eksik veri kaldığı teyit edildi.

Kullandığım veri seti: Titanic Veri Seti – train.csv

Ürettiğim notebook / dosya: 04_data_exploration.ipynb

Öğrendiğim en önemli 3 şey:

Eksik Veri Stratejileri: Eksik verilerin oranına göre hareket edilmelidir; Cabin gibi %70'in üzerinde boş olan alanlar bilgi kaybı yaratmayacak kategorilere dönüştürülmeli ('Unknown'), Age gibi sayısal değişkenlerde aykırı değerlerden etkilenmemek adına medyan, Embarked gibi kategorik sütunlarda ise mod tercih edilmelidir.

Özet İstatistiklerden Dağılım Okuma: describe() tablosunda bilet ücreti (Fare) medyanının 14.45 iken maksimum değerinin 512.33 olması belirgin aykırı değerleri doğrudan gösterir.

Model Öncesi Matris Kalitesi ve Denge: Girdi matrisinde (X) eksik değer kalmaması makine öğrenmesi algoritmalarının kararlılığı için zorunludur; ayrıca hedef değişkendeki yaklaşık %62-%38 dağılımın aşırı bir sınıf dengesizliği taşımadığını doğrulamak modelin yanıltıcı metriklere düşmesini engeller.

Zorlandığım konu: apply() fonksiyonunda axis='columns' ile satır düzeyinde gezinirken birden fazla sütun şartını (Age ve Sex) içeren mantıksal kontrolleri kurmak ve merkezileştirme işleminde ortalama farkının vektörel olarak doğru yansıdığını doğrulamak.

Sormak istediğim konu: Çok az eksik değere sahip kategorik sütunlarda (Embarked içindeki 2 eksik gözlem gibi) mod ile doldurma yapmak yerine, veri kaybı ihmal edilebilir düzeyde olduğu için bu satırları doğrudan silmek model performansı veya veri yanlılığı açısından daha mı sağlıklı bir tercihtir?

Gelecek hafta hedefim: Hafta 5 konum olan Veri Analizi ve Görselleştirme konularına çalışmak.